

Klasyfikacja jakości napojów przy użyciu Random Forest i PCA: Raport Techniczny

Autor: Tomasz Biel

Numer studenta: 10520587

Data: 2025

1. Wprowadzenie

Niniejsze opracowanie przedstawia analizę klasyfikacyjną jakości napojów na podstawie ich właściwości fizykochemicznych. Wykorzystano metody nadzorowanego i nienadzorowanego uczenia maszynowego, w tym klasyfikatory typu Random Forest oraz drzewa decyzyjne, a także redukcję wymiarów (PCA) oraz grupowanie (KMeans).

Zbiór danych zawiera 4898 obserwacji, każda z 11 cechami numerycznymi i jedną zmienną docelową (`quality`). Celem projektu było zbudowanie modelu predykcyjnego, który pozwala na skuteczne odróżnianie napojów wysokiej jakości (oznaczonych jako "Excellent") od pozostałych.

2. Przygotowanie danych i wstępne przetwarzanie

- **Transformacja zmiennej docelowej:**

- `Excellent` → 1

- Pozostałe → 0

- **Kodowanie cech:**

- Trzy cechy (`alcohol`, `volatile acidity`, `sulphates`) zakodowano metodą one-hot encoding, co pozwalało na uchwycenie ich dyskretnych wartości jako zmiennych binarnych.

- **Standaryzacja:**

- Wszystkie zmienne zostały przeskalowane do tej samej skali za pomocą `StandardScaler`.

- **Nieźrównoważone klasy:**

- Początkowo w zbiorze treningowym było:

- 745 obserwacji klasy pozytywnej (1)
- 2683 obserwacji klasy negatywnej (0)

- Zastosowano technikę **SMOTE**, aby uzyskać po 2683 próbki dla każdej klasy (balans danych).

3. Modele nadzorowane (Supervised Learning)

3.1 Drzewo decyzyjne (Decision Tree)

- **Kryterium podziału:** entropia (entropy)
- **Maksymalna głębokość drzewa:** 5

- **Dokładność predykcji (accuracy):** 0,715
- **Macierz pomyłek (confusion matrix):**
 - Prawdziwie pozytywne (TP): 215
 - Prawdziwie negatywne (TN): 836
 - Fałszywie pozytywne (FP): 319
 - Fałszywie negatywne (FN): 100
- **Średnia dokładność w walidacji krzyżowej (5-krotnej):** 0,724
- **Odchylenie standardowe dokładności:** 0,022

3.2 Random Forest (las losowy)

- **Model bazowy:**
 - Parametry: `n_estimators=300`, `max_features='sqrt'`, `criterion='entropy'`
 - **Accuracy:** 0,883
 - **TP:** 211, **TN:** 1087, **FP:** 68, **FN:** 104
- **Optimalizacja hiperparametrów (GridSearchCV):**
 - Najlepsze parametry:
 - `n_estimators=450`
 - `max_depth=30`
 - Wynik walidacji krzyżowej: 0,918
 - Accuracy na zbiorze testowym: 0,881
- **Ważność cech (feature importance) – 5 najważniejszych:**
 - `density`: 0,401
 - `residual sugar`: 0,198
 - `citric acid`: 0,187
 - `free sulfur dioxide`: 0,093
 - `chlorides`: 0,056

Warto zauważyć, że zakodowane cechy `alcohol_...` miały marginalny wpływ (wiele z nich z wartością bliską 0).

4. Uczenie nienadzorowane: PCA i KMeans

4.1 PCA (analiza głównych składowych)

- Użyto dwóch składowych głównych (components):
 - Pierwsza: 1,09% wariancji
 - Druga: 0,80%
- **Łącznie wyjaśniona wariancja:** 1,89%
- Wykres PCA ukazał koncentrację obserwacji z kilkoma wartościami odstającymi (outliers) oraz lekkim przesunięciem kierunkowym (bias).

4.2 Klasteryzacja KMeans

- Przeprowadzono analizę Elbow Plot dla zakresu klastrow 1–10.
 - Optymalna liczba klastrow: **4** (punkt załamania krzywej).
 - Klasteryzacja została przedstawiona na wykresie PCA. Klastery wykazują zróżnicowaną strukturę, co wspiera wcześniejsze ustalenia modelu RF.
-

5. Wnioski i rekomendacje

- **Czynniki decydujące o wysokiej jakości:**
 - Zawartość **alkoholu**: najlepsze wyniki uzyskano przy wartościach ok. **9.2–9.4**
 - Niskie wartości **lotnej kwasowości** (`volatile acidity`), **cukru resztkowego** i **siarczynów**
 - **Najlepszy model**: Random Forest z 450 drzewami, głębokością 30
 - **Znaczenie zmiennych**: Zmienna `density` miała największy wpływ na wynik modelu, przewyższając nawet `alcohol`, który po zakodowaniu utracił część informacyjności.
 - **Wydajność modelu**: Wysoka skuteczność modelu RF wskazuje na dobrą separację klas, szczególnie po zbalansowaniu danych i dostrojeniu hiperparametrów.
 - **PCA i KMeans**: Pomogły zweryfikować strukturę danych i pokazały możliwość ich rozdzielenia nawet bez nadzoru.
-

6. Podsumowanie

Projekt ukazuje, jak efektywnie można zastosować klasyfikację do problemu jakości produktów. Random Forest okazał się najbardziej skuteczną metodą predykcji, zwłaszcza po dostrojeniu parametrów i zastosowaniu SMOTE. PCA i KMeans dostarczyły dodatkowych informacji o strukturze danych i potwierdziły wybór najistotniejszych cech.

Całość stanowi kompleksowy przykład zastosowania uczenia maszynowego w kontroli jakości – z możliwością adaptacji do innych zestawów danych przemysłowych.

Słowa kluczowe: Random Forest, SMOTE, Decision Tree, PCA, KMeans, jakość napoju, klasyfikacja, znaczenie cech, optymalizacja hiperparametrów